

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO DE JANEIRO – PUC-RIO

PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS E ANALYTICS

MVP DE ENGENHARIA DE DADOS

Análise de Acidentes em Rodovias Federais Brasileiras em 2025

Delianne Fernandes Purgato

Matrícula: 4052026000610

Disciplina: Engenharia de Dados

Rio de Janeiro

2026

SUMÁRIO

1. INTRODUÇÃO.....	3
2. OBJETIVO.....	4
2.1 Perguntas de negócio.....	4
3. FONTE DOS DADOS.....	4
4. COLETA E INGESTÃO DOS DADOS.....	5
4.1 Preparação do ambiente.....	6
4.2 Validação da Ingestão.....	7
4.2.1 Estrutura dos dados de origem.....	7
5. MODELAGEM.....	8
5.1 Arquitetura de Dados.....	8
5.2 Modelo Dimensional.....	9
5.3 Catálogo de Dados.....	10
5.3.1 Contexto das tabelas.....	11
5.3.2 Evidência do catálogo no Databricks.....	13
5.4 Linhagem dos Dados.....	13
6. CARGA DOS DADOS.....	14
6.1 Carga na Camada Bronze.....	15
6.2 Transformação e Carga na Camada Silver.....	15
6.3 Carga na Camada Gold.....	17
7. ANÁLISE.....	19
7.1 Qualidade dos Dados.....	19
7.1.1 Qualidade dos Atributos.....	20
7.2 Solução do Problema.....	24
8. CONCLUSÃO.....	33
9. AUTOAVALIAÇÃO.....	34

1. INTRODUÇÃO

Os acidentes de trânsito representam um importante problema para a segurança viária, podendo resultar em vítimas, impactos sociais e prejuízos materiais. A análise de dados relacionados a essas ocorrências permite identificar padrões e características que podem contribuir para uma melhor compreensão do cenário dos acidentes nas rodovias.

Este MVP tem como foco a construção de uma solução de Engenharia de Dados utilizando a plataforma Databricks, a partir de dados públicos de acidentes disponibilizados pela Polícia Rodoviária Federal (PRF).

O projeto contempla as etapas de coleta e ingestão dos dados, persistência em nuvem, análise da qualidade, transformação, modelagem e disponibilização das informações para análise.

2. OBJETIVO

O objetivo deste MVP é construir uma solução de Engenharia de Dados no Databricks para coletar, armazenar, tratar, modelar e analisar os dados de acidentes ocorridos nas rodovias federais brasileiras em 2025, disponibilizados pela Polícia Rodoviária Federal (PRF).

A partir da organização e preparação desses dados, busca-se identificar padrões relacionados à ocorrência e à gravidade dos acidentes e produzir informações que auxiliem na compreensão do cenário da segurança viária nas rodovias federais.

2.1 Perguntas de negócio

1. Quais são as principais causas dos acidentes registrados nas rodovias federais em 2025?
2. Em quais dias da semana e horários ocorre o maior número de acidentes?
3. Quais estados e rodovias federais concentram o maior número de acidentes?
4. Quais tipos de acidentes apresentam os maiores números de vítimas fatais?
5. Existe relação entre as condições meteorológicas, características da pista e a ocorrência de acidentes?
6. Quais características se destacam entre as ocorrências com vítimas fatais?

3. FONTE DOS DADOS

Para o desenvolvimento deste MVP foi utilizado o conjunto de dados de acidentes de trânsito disponibilizado pela Polícia Rodoviária Federal (PRF) em seu Portal de Dados Abertos.

Foi selecionada a base de acidentes agrupados por ocorrência referente ao ano de 2025, disponibilizada em formato CSV. Cada registro representa uma ocorrência de acidente em rodovia federal e contém informações relacionadas à data e horário, localização, características da via, condições meteorológicas, causa e tipo do acidente, além da quantidade de pessoas, veículos, feridos e mortos envolvidos.

Fonte: Polícia Rodoviária Federal (PRF) – Dados Abertos

Período analisado: 2025

Formato de origem: CSV

Arquivo: dataatran2025.csv

Disponível em: [Portal de Dados Abertos da PRF](#)

Condições de uso: Dados abertos de uso livre, permitindo utilização, reutilização e redistribuição, conforme a Política de Dados Abertos da PRF.

Dados Abertos da PRF

Publicado em 19/04/2022 06:50 | Modificado em 28/07/2026 15:45

Compartilhe: [📄](#) [X](#) [f](#) [in](#) [🔗](#)

Dados Abertos são dados institucionais, disponibilizados em formato legível por máquina e sem restrição de licenças, patentes ou mecanismos de controle, que qualquer pessoa pode livremente usá-los, reutilizá-los e redistribuí-los.

≡ Polícia Rodoviária Federal

Documento CSV de Acidentes 2025 (Agrupados por ocorrência)

[Baixar planilha](#)

Figura 1 – Fonte dos dados utilizada no projeto.

Fonte: Polícia Rodoviária Federal (PRF).

4. COLETA E INGESTÃO DOS DADOS

Os dados utilizados neste projeto foram obtidos a partir do conjunto de Dados Abertos da Polícia Rodoviária Federal (PRF), considerando os acidentes agrupados por ocorrência referentes ao ano de 2025.

O arquivo de origem, disponibilizado em formato CSV, foi ingerido no ambiente Databricks e persistido na plataforma de nuvem para utilização nas etapas posteriores do pipeline de dados.

Durante a ingestão, foi identificado que o arquivo utiliza ponto e vírgula (;) como delimitador. Essa configuração foi considerada durante a leitura do arquivo para que os atributos fossem corretamente reconhecidos e separados em colunas. Os dados provenientes da fonte foram então persistidos na Camada Bronze, preservando as informações para posterior tratamento nas etapas seguintes do pipeline.

Os dados originais foram armazenados na tabela:

'workspace.bronze.bronze_acidentes_prf_2025'

A tabela Bronze representa a camada de dados brutos do projeto, preservando os dados provenientes da fonte antes da aplicação das regras de tratamento, qualidade e modelagem.

4.1 Preparação do ambiente

Para organizar o pipeline conforme a arquitetura Medalhão adotada no projeto, foram utilizados schemas distintos no catálogo workspace: bronze, silver e gold. Essa organização permite separar os dados de acordo com seu estágio de processamento, mantendo os dados de origem na Camada Bronze, os dados tratados e padronizados na Camada Silver e o modelo dimensional destinado às análises na Camada Gold.




Figura 2 – Organização dos schemas da arquitetura medalhão no Databricks.
Fonte: Elaborado pela autora a partir do Databricks

- **Ingestão dos dados na Camada Bronze**

Após a preparação do ambiente, o arquivo **datatran2025.csv** foi lido a partir do volume de armazenamento do Databricks e persistido na tabela **workspace.bronze.bronze_acidentes_prf_2025**, correspondente à Camada Bronze do pipeline. Nesta etapa, os dados foram mantidos conforme a estrutura de origem, sem aplicação das transformações destinadas à Camada Silver.

```
▶ ✓ 3 days ago (5s) 11

1 df_bronze = (
2     spark.read
3     .option("header", "true")
4     .option("sep", ";")
5     .option("encoding", "windows-1252")
6     .option("inferSchema", "false")
7     .csv("/Volumes/workspace/default/arquivo_mvp/datatran2025.csv")
8 )
9
10 df_bronze.write \
11     .mode("overwrite") \
12     .option("overwriteSchema", "true") \
13     .saveAsTable("workspace.bronze.bronze_acidentes_prf_2025")

> See performance \(1\)
```

4.2 Validação da Ingestão

Após a criação da tabela Bronze, foi realizada uma validação da ingestão para verificar a quantidade de registros carregados e visualizar uma amostra dos dados.

A tabela apresentou 72.529 registros, confirmando a carga do conjunto de dados utilizado no projeto.

```
▶ ✓ Sep 07, 2026 (4s) 11

%sql
SELECT COUNT(*) AS total_registros
FROM workspace.bronze.bronze_acidentes_prf_2025;


> See performance \(1\)
```

Table ▾		+
	1 ² total_registros	
1	72529	

Figura 3 – Validação da quantidade de registros carregados na Camada Bronze.
Fonte: Elaborado pela autora a partir do Databricks

4.2.1 Estrutura dos dados de origem

Após a ingestão, também foi verificada a estrutura da tabela Bronze, permitindo identificar os atributos e os respectivos tipos de dados provenientes do arquivo datatran2025.csv. Essa validação confirmou que os campos necessários para as etapas posteriores do pipeline foram corretamente reconhecidos e persistidos no Databricks.



3 days ago (1s) 15

```
1 %sql
2 DESCRIBE TABLE workspace.bronze.bronze_acidentes_prf_2025;
```

> [See performance \(1\)](#)

Table ▾ +

	^A _C col_name	^A _C data_type	^A _C comment
16	tracado_via	string	null
17	uso_solo	string	null
18	peessoas	string	null
19	mortos	string	null
20	feridos_leves	string	null
21	feridos_graves	string	null
22	ilesos	string	null
23	ignorados	string	null
24	feridos	string	null
25	veiculos	string	null
26	latitude	string	null

Figura 4 – Estrutura dos atributos da Camada Bronze.
Fonte: Elaborado pela autora a partir do Databricks

5. MODELAGEM

5.1 Arquitetura de Dados

O projeto foi estruturado no Databricks utilizando uma arquitetura medalhão:

- Bronze: armazenamento dos dados provenientes do arquivo de origem;
- Silver: dados tratados e padronizados para utilização nas etapas seguintes;
- Gold: dados organizados em modelo dimensional para realização das análises.

Essa organização permite separar os dados de origem, os processos de transformação e a camada destinada ao consumo analítico.

5.2 Modelo Dimensional

Para a Camada Gold foi adotado um modelo dimensional em esquema estrela, composto por quatro dimensões e uma tabela fato.

As dimensões representam os principais contextos de análise:

- **dim_tempo:** informações relacionadas à data da ocorrência;
- **dim_localidade:** estado e município;
- **dim_via:** características da rodovia e da pista;
- **dim_acidente:** características e classificação do acidente.

A tabela **fato_acidentes** concentra as métricas relacionadas às ocorrências e mantém o relacionamento com as dimensões por meio de suas respectivas chaves.




Figura 5 – Modelo dimensional em esquema estrela da Camada Gold.
Fonte: Elaborado pela autora.

5.3 Catálogo de Dados

O catálogo de dados apresenta a descrição dos atributos que compõem o modelo dimensional, seus respectivos tipos e domínios de valores, auxiliando na compreensão da estrutura disponibilizada para análise.

5.3.1 Contexto das tabelas

O modelo dimensional da Camada Gold é composto por uma tabela fato e quatro dimensões: a **fato_acidentes**, que concentra as métricas relacionadas às ocorrências e as chaves de relacionamento com as dimensões; a **dim_tempo**, responsável pelos atributos relacionados à data; a **dim_localidade**, que contém as informações de unidade federativa e município; a **dim_via**, que reúne as características da rodovia e da via; e a **dim_acidente**, que concentra as características relacionadas à causa, tipo, classificação e condições do acidente.

Tabela	Atributo	Descrição	Tipo	Domínio / Valores
dim_tempo	tempo_key	Chave da dimensão tempo	Numérico	Chave técnica
dim_tempo	data	Data da ocorrência	Data	Ano de 2025
dim_tempo	dia_semana	Dia da semana da ocorrência	Categórico	segunda-feira a domingo
dim_tempo	ano	Ano da ocorrência	Numérico	2025
dim_tempo	mes	Mês da ocorrência	Numérico	Mín. 1 / Máx. 12
dim_tempo	dia	Dia do mês da ocorrência	Numérico	Mín. 1 / Máx. 31

dim_localidade	localidade_key	Chave da dimensão localidade	Numérico	Chave técnica
dim_localidade	uf	Unidade Federativa	Categórico	AC, AL, AM, AP, BA, CE, DF, ES, GO, MA, MG, MS, MT, PA, PB, PE, PI, PR, RJ, RN, RO, RR, RS, SC, SE, SP, TO
dim_localidade	municipio	Município da ocorrência	Categórico	Municípios presentes na base

dim_via	via_key	Chave da dimensão via	Numérico	Chave técnica
dim_via	br	Número da rodovia federal	Numérico	Mín. 0 / Máx. 495
dim_via	km	Quilômetro da ocorrência	Numérico	Mín. 0,00 / Máx. 1.257,00
dim_via	sentido_via	Sentido da via	Categórico	Crescente, Decrescente, Não Informado
dim_via	tipo_pista	Tipo da pista	Categórico	Dupla, Múltipla, Simples
dim_via	tracado_via	Características do traçado da via	Categórico multivalorado	605 combinações observadas, incluindo Reta, Curva, Declive, Aclive, Interseção de Vias e combinações entre essas características
dim_via	uso_solo	Indicação de uso do solo	Categórico	Não, Sim

dim_acidente	acidente_key	Chave da dimensão acidente	Numérico	Chave técnica
dim_acidente	causa_acidente	Causa registrada para o acidente	Categórico	Causas presentes na base
dim_acidente	tipo_acidente	Tipo do acidente	Categórico	Tipos presentes na base
dim_acidente	classificacao_acidente	Classificação do acidente	Categórico	Com Vítimas Fatais, Com Vítimas Feridas, NA, Sem Vítimas
dim_acidente	fase_dia	Fase do dia	Categórico	Amanhecer, Anoitecer, Plena Noite, Pleno dia
dim_acidente	condicao_meteorologica	Condição meteorológica	Categórico	Chuva, Céu Claro, Garoa/Chuvisco, Ignorado, Neve, Nevoeiro/Neblina, Nublado, Sol, Vento

fato_acidentes	acidente_id	Identificador da ocorrência	Numérico	Identificador
fato_acidentes	tempo_key	Chave de relacionamento com dim_tempo	Numérico	Chave estrangeira
fato_acidentes	localidade_key	Chave de relacionamento com dim_localidade	Numérico	Chave estrangeira
fato_acidentes	via_key	Chave de relacionamento com dim_via	Numérico	Chave estrangeira
fato_acidentes	acidente_key	Chave de relacionamento com dim_acidente	Numérico	Chave estrangeira
fato_acidentes	horario	Horário da ocorrência	Categórico	HH:mm:ss
fato_acidentes	peessoas	Quantidade de pessoas envolvidas	Numérico	Mín. 1 / Máx. 76

fato_acidentes	mortos	Quantidade de mortos	Numérico	Mín. 0 / Máx. 16
fato_acidentes	feridos_leves	Quantidade de feridos leves	Numérico	Mín. 0 / Máx. 41
fato_acidentes	feridos_graves	Quantidade de feridos graves	Numérico	Mín. 0 / Máx. 22
fato_acidentes	ilesos	Quantidade de pessoas ilesas	Numérico	Mín. 0 / Máx. 71
fato_acidentes	ignorados	Quantidade de pessoas com condição ignorada	Numérico	Mín. 0 / Máx. 81
fato_acidentes	feridos	Total de feridos	Numérico	Mín. 0 / Máx. 49
fato_acidentes	veiculos	Quantidade de veículos	Numérico	Mín. 1 / Máx. 82

Figura 6 – Catálogo de dados do modelo dimensional.
Fonte: Elaborado pela autora a partir do Databricks

5.3.2 Evidência do catálogo no Databricks

As tabelas utilizadas no pipeline foram persistidas no catálogo workspace do Databricks, organizadas em schemas distintos de acordo com as camadas da arquitetura medalhão. A Camada Bronze foi armazenada no schema bronze, a Camada Silver no schema silver e as dimensões e a tabela fato da Camada Gold no schema gold.




Figura 7 – Tabelas do pipeline organizadas nos schemas Bronze, Silver e Gold.
Fonte: Elaborado pela autora a partir do Databricks.

5.4 Linhagem dos Dados

A linhagem dos dados representa o fluxo das informações desde a fonte de origem até a disponibilização para análise. Os dados do arquivo CSV da PRF são inseridos na Camada Bronze, posteriormente tratados e padronizados na Camada Silver e, por fim, utilizados na construção das dimensões e da tabela fato da Camada Gold.




Figura 8 – Linhagem dos dados do pipeline.

Fonte: Elaborado pela autora.

6. CARGA DOS DADOS


Nesta etapa, são apresentados os processos de carga e transformação dos dados nas camadas Bronze, Silver e Gold. O pipeline foi desenvolvido no Databricks, partindo da persistência dos dados brutos, passando pelo tratamento e padronização das informações e finalizando com a construção do modelo dimensional utilizado nas análises.

O pipeline de dados foi implementado em um único notebook no Databricks, utilizando SQL e PySpark e organizado de forma sequencial. O fluxo contempla a ingestão e persistência dos dados na Camada Bronze, o tratamento e a padronização na Camada Silver e a construção do modelo dimensional na Camada Gold. As etapas e os respectivos códigos de transformação e carga estão documentados no notebook disponibilizado juntamente com o projeto.

6.1 Carga na Camada Bronze

Conforme apresentado na etapa de coleta e ingestão, o arquivo **datatran2025.csv** foi lido a partir do volume de armazenamento do Databricks utilizando PySpark e persistido na tabela **workspace.bronze.bronze_acidentes_prf_2025**.

Essa tabela constitui a Camada Bronze do pipeline e preserva os dados provenientes da fonte de origem antes das transformações realizadas na Camada Silver.



The screenshot displays the Databricks Catalog Explorer interface. On the left, the 'Catalog' sidebar shows the hierarchy: 'My organization' > 'workspace' > 'bronze' > 'Tables (1)' > 'bronze_acidentes_prf_2025'. The right pane shows the table's details, including a description 'Created by the file upload UI' and a table of columns.

Column	Type	Popula...
id	string	.all
data_inversa	string	.all
dia_semana	string	.all
horario	string	.all
uf	string	.all
br	string	.all

Figura 9 – Persistência da tabela na Camada Bronze no Databricks.
Fonte: Elaborado pela autora a partir do Databricks.

6.2 Transformação e Carga na Camada Silver

A Camada Silver foi construída a partir dos dados armazenados na Camada Bronze, com o objetivo de padronizar os atributos e adequar os tipos de dados para utilização nas etapas posteriores do pipeline.

Durante o processo de transformação, foram realizados os seguintes tratamentos:

- conversão do campo id para tipo numérico;
- conversão do campo data_inversa para o tipo DATE;
- conversão do campo br para tipo numérico;
- manutenção do campo horario no formato HH:mm:ss;
- conversão do campo km para o tipo decimal, substituindo a vírgula pelo ponto;
- conversão dos campos quantitativos pessoas, mortos, feridos_leves, feridos_graves, ilesos, ignorados, feridos e veiculos para tipo inteiro;
- conversão dos campos latitude e longitude para o tipo decimal;
- inclusão do atributo silver_load_timestamp para registrar o momento de processamento da carga.
- inclusão de comentários descritivos nos atributos da Camada Silver, contribuindo para a documentação e governança dos dados

Após as transformações, os dados foram persistidos na tabela **workspace.silver.silver_acidentes_prf_2025**.

```
1 %sql
2 CREATE OR REPLACE TABLE workspace.silver.silver_acidentes_prf_2025 AS
3 SELECT
4     CAST(id AS BIGINT) AS id,
5     CAST(data_inversa AS DATE) AS data_inversa,
6     dia_semana,
7     horario,
8     uf,
9     CAST(br AS INT) AS br,
10    CAST(REPLACE(km, ',', '.') AS DECIMAL(10,2)) AS km,
11    municipio,
12    causa_acidente,
13    tipo_acidente,
14    classificacao_acidente,
15    fase_dia,
16    sentido_via,
17    condicao_meteorologica,
18    tipo_pista,
19    tracado_via
```

Figura 10 – Processo de transformação e carga dos dados na Camada Silver.
Fonte: Elaborado pela autora a partir do Databricks.

6.3 Carga na Camada Gold

A Camada Gold foi estruturada utilizando um modelo dimensional em esquema estrela, construído a partir dos dados tratados na Camada Silver.

Foram criadas quatro tabelas dimensão — **dim_tempo**, **dim_localidade**, **dim_via** e **dim_acidente** — responsáveis por armazenar os diferentes contextos de análise.

Posteriormente, foi criada a tabela **fato_acidentes**, contendo as métricas das ocorrências e as chaves de relacionamento com as dimensões. Essa estrutura foi utilizada como base para as consultas analíticas e para responder às perguntas de negócio definidas no projeto.

```
▶ ✓ Sep 07, 2026 (5s) 35

1 %sql
2 CREATE OR REPLACE TABLE workspace.gold.dim_tempo AS
3 SELECT DISTINCT
4     CAST(date_format(data_inversa, 'yyyyMMdd') AS INT) AS tempo_key,
5     data_inversa AS data,
6     dia_semana,
7     YEAR(data_inversa) AS ano,
8     MONTH(data_inversa) AS mes,
9     DAY(data_inversa) AS dia
10 FROM workspace.silver.silver_acidentes_prf_2025;
11

> See performance \(1\)
```

Figura 11 – Criação de uma tabela dimensão da Camada Gold no Databricks.
Fonte: Elaborado pela autora a partir do Databricks.

```
▶ ✓ Sep 07, 2026 (7s) 44

1 %sql
2 CREATE OR REPLACE TABLE workspace.gold.fato_acidentes AS
3 SELECT
4     s.id AS acidente_id,
5     t.tempo_key,
6     l.localidade_key,
7     v.via_key,
8     a.acidente_key,
9     s.horario,
10    s.pessoas,
11    s.mortos,
12    s.feridos_leves,
13    s.feridos_graves,
14    s.ilesos,
15    s.ignorados,
16    s.feridos,
17    s.veiculos
18 FROM workspace.silver.silver_acidentes_prf_2025 s
19
20 INNER JOIN workspace.gold.dim_tempo t
21 ON s.data_inversa = t.data
```

Figura 12 – Construção da tabela fato e relacionamento com as dimensões.
Fonte: Elaborado pela autora a partir do Databricks.

7. ANÁLISE

Após a construção do modelo dimensional, foram realizadas análises para verificar a qualidade dos dados e responder às perguntas de negócio definidas no início do projeto.

7.1 Qualidade dos Dados

Inicialmente, foi verificada a consistência dos dados ao longo do pipeline, comparando a quantidade de registros armazenados nas camadas Bronze, Silver e Gold.

A validação demonstrou que os 72.529 registros foram mantidos ao longo das etapas de transformação e modelagem, não sendo identificada perda de registros entre as camadas.




Figura 13 – Validação da quantidade de registros entre as camadas Bronze, Silver e Gold.
Fonte: Elaborado pela autora a partir do Databricks.

7.1.1 Qualidade dos Atributos

Para avaliar a qualidade do conjunto de dados, foram analisados os atributos da Camada Silver, verificando a presença de valores nulos e a quantidade de valores distintos em cada campo.

Não foram identificados valores nulos nos atributos analisados. A quantidade de valores distintos também se mostrou compatível com os domínios esperados, como 365 datas, 7 dias da semana, 27 UF's, 4 classificações de acidente e 3 tipos de pista.

Durante o processo de preparação dos dados, também foram observadas categorias como NA, Não Informado e Ignorado, que representam classificações existentes no conjunto de dados e foram mantidas para preservar as informações da fonte.

Além da análise de completude, foram realizadas verificações de unicidade, consistência e plausibilidade dos dados, permitindo identificar possíveis duplicidades, valores fora dos domínios esperados e valores quantitativos inválidos.

Após os tratamentos realizados na Camada Silver, os dados apresentaram consistência adequada para a construção do modelo dimensional e para a realização das análises propostas.

	A_C^B atributo	1^2_3 nulos	1^2_3 distintos
1	id	0	72529
2	data_inversa	0	365
3	dia_semana	0	7
4	horario	0	1412
5	uf	0	27
6	br	0	115
7	km	0	7655
8	municipio	0	1844
9	causa_acidente	0	69
10	tipo_acidente	0	17
11	classificacao_acidente	0	4
12	fase_dia	0	4
13	sentido_via	0	3
14	condicao_metereologi...	0	9
15	tipo_pista	0	3

	A_C^B atributo	1^2_3 nulos	1^2_3 distintos
17	uso_solo	0	2
18	peessoas	0	66
19	mortos	0	12
20	feridos_leves	0	33
21	feridos_graves	0	18
22	ilesos	0	57
23	ignorados	0	18
24	feridos	0	38
25	veiculos	0	21
26	latitude	0	68989
27	longitude	0	68885
28	regional	0	29
29	delegacia	0	154
30	uop	0	396
31	silver_load_timestamp	0	1

Figura 14 – Análise de completude e quantidade de valores distintos dos atributos da Camada Silver.
Fonte: Elaborado pela autora a partir do Databricks.

- **Unicidade:** não foram identificados registros duplicados com base no atributo id, utilizado como identificador da ocorrência. A quantidade total de registros é igual à quantidade de identificadores distintos, evidenciando a unicidade das ocorrências analisadas.

▶ ✓ Sep 07, 2026 (2s) 54

```

1 %sql
2 SELECT
3     COUNT(*) AS total_registros,
4     COUNT(DISTINCT id) AS ids_distintos,
5     COUNT(*) - COUNT(DISTINCT id) AS ids_duplicados
6 FROM workspace.silver.silver_acidentes_prf_2025;

```

> [See performance \(1\)](#)

Table ▾ +

	¹ ₃ total_registros	¹ ₃ ids_distintos	¹ ₃ ids_duplicados
1	72529	72529	0

Figura 15 – Validação de unicidade dos registros da Camada Silver.
Fonte: Elaborado pela autora a partir do Databricks.

- **Consistência:** não foram identificados valores fora dos domínios esperados para os atributos uf, dia_semana e tipo_pista. As três validações retornaram zero registros inválidos, indicando consistência dos valores categóricos avaliados.

Table ▾ +

	^A _C validacao	¹ ₃ registros
1	UF inválida	0
2	Dia da semana inváli...	0
3	Tipo de pista inválido	0

Figura 16 – Validação de consistência dos domínios dos atributos categóricos.
Fonte: Elaborado pela autora a partir do Databricks.

- Plausibilidade dos dados:** foram realizadas validações nos atributos quantitativos relacionados às pessoas e aos veículos envolvidos nas ocorrências. Não foram identificados valores negativos nos campos de pessoas, mortos, feridos, ilesos ou ignorados, nem valores inválidos para a quantidade de veículos, indicando valores plausíveis para esses atributos.



The screenshot shows a Databricks SQL interface. At the top, a query is executed on 'Sep 07, 2026 (1s)' with a progress bar at 58%. The query is a SELECT statement with several SUM(CASE WHEN) clauses to check for negative values in various accident-related fields. Below the query, a table titled 'Table' displays the results. The table has five columns: '1 pessoas_negativas', '1 mortos_negativos', '1 feridos_leves_negativos', '1 feridos_graves_negativos', and '1 ilesos_negativos'. All five columns show a value of 0, indicating no negative values were found.

```

5 SUM(CASE WHEN feridos_graves < 0 THEN 1 ELSE 0 END) AS feridos_graves_negativos,
6 SUM(CASE WHEN ilesos < 0 THEN 1 ELSE 0 END) AS ilesos_negativos,
7 SUM(CASE WHEN ignorados < 0 THEN 1 ELSE 0 END) AS ignorados_negativos,
8 SUM(CASE WHEN feridos < 0 THEN 1 ELSE 0 END) AS feridos_negativos,
9 SUM(CASE WHEN veiculos <= 0 THEN 1 ELSE 0 END) AS veiculos_invalidos
10 FROM workspace.silver.silver_acidentes_prf_2025;
11

```

	1 pessoas_negativas	1 mortos_negativos	1 feridos_leves_negativos	1 feridos_graves_negativos	1 ilesos_negativos
1	0	0	0	0	0

Figura 17 – Validação de plausibilidade dos atributos quantitativos.
 Fonte: Elaborado pela autora a partir do Databricks

- Análise de valores extremos:** foram avaliados os valores mínimos e máximos dos atributos quantitativos. Os resultados apresentaram valores entre 1 e 76 pessoas por ocorrência, 0 e 16 mortos, 0 e 41 feridos leves, 0 e 22 feridos graves, 0 e 71 ilesos, 0 e 81 registros ignorados, 0 e 49 feridos e entre 1 e 82 veículos envolvidos. Embora alguns valores máximos sejam elevados em relação à maioria das ocorrências, não foram identificados valores impossíveis com base nas regras de domínio avaliadas. Dessa forma, esses registros foram preservados para as análises.



Figura 18 – Valores mínimos e máximos dos atributos quantitativos da Camada Silver.
 Fonte: Elaborado pela autora a partir do Databricks

7.2 Solução do Problema

A partir dos dados organizados na Camada Gold, foram realizadas consultas analíticas para responder às perguntas de negócio definidas no início do projeto. Os resultados obtidos são apresentados e discutidos a seguir.

1. Quais são as principais causas dos acidentes registrados nas rodovias federais em 2025?

```
ORDER BY total_acidentes DESC
LIMIT 10;
```

Table		Principais causas de acidentes - 2025	+
	^A _C causa_acidente	¹ ₃ total_acidentes	
1	Ausência de reação do condutor	11469	
2	Reação tardia ou ineficiente do condutor	10799	
3	Acessar a via sem observar a presença dos outros veícul...	7097	
4	Condutor deixou de manter distância do veículo da frente	4413	
5	Velocidade Incompatível	4088	
6	Manobra de mudança de faixa	4016	
7	Ingestão de álcool pelo condutor	3685	
8	Demais falhas mecânicas ou elétricas	3385	
9	Transitar na contramão	2475	
10	Condutor Dormindo	2116	


10 rows | 1.787s runtime

Figura 19 – Principais causas dos acidentes registrados em 2025.

Fonte: Elaborado pela autora a partir do Databricks

Resultado: A ausência de reação do condutor foi a principal causa de acidentes registrada em 2025, com 11.469 ocorrências, seguida pela reação tardia ou ineficiente do condutor, com 10.799 ocorrências.

2. Em quais dias da semana e horários ocorre o maior número de acidentes?



The screenshot shows a Databricks SQL interface. At the top, a status bar indicates '2 days ago (2s)' and '48'. Below it, a SQL query is displayed: `ON f.tempo_key = t.tempo_key`, `GROUP BY t.dia_semana`, and `ORDER BY total_acidentes DESC;`. The query result is shown in a table format with a 'Table' dropdown and a '+' icon. The table has two columns: 'dia_semana' and 'total_acidentes'. The data is sorted in descending order of total accidents. At the bottom, there are controls for downloading the data, a dropdown arrow, and a summary: '7 rows | 2.147s runtime'.

	^A _C dia_semana	¹ ₃ total_acidentes
1	sábado	11554
2	domingo	11470
3	sexta-feira	11197
4	segunda-feira	10285
5	quarta-feira	9556
6	quinta-feira	9405
7	terça-feira	9062

7 rows | 2.147s runtime

Figura 20 – Distribuição dos acidentes por dia da semana.
Fonte: Elaborado pela autora a partir do Databricks




Figura 21 – Distribuição dos acidentes por horário.
Fonte: Elaborado pela autora a partir do Databricks




Figura 22 – Distribuição dos acidentes por horário em representação gráfica
Fonte: Elaborado pela autora a partir do Databricks

Resultado: O sábado apresentou o maior número de acidentes, com 11.554 ocorrências. Em relação ao horário, a maior concentração foi registrada às 18h, com 5.398 acidentes, seguida pelas 17h, com 4.845, e 19h, com 4.646 ocorrências.

3. Quais estados e rodovias concentram o maior número de acidentes?

▶ ✓ Sep 07, 2026 (2s)

10 LIMIT 10;

> See performance (1)

Table ▾ +

	^A _C uf	¹ ₃ total_acidentes
1	MG	9570
2	SC	8186
3	PR	7630
4	RJ	6428
5	RS	4899
6	SP	4683
7	BA	4108
8	GO	3196
9	PE	3013
10	ES	2642

Figura 23 – Estados com maior número de acidentes registrados em 2025.
Fonte: Elaborado pela autora a partir do Databricks

```

▶ ✓ Sep 07, 2026 (2s)

7 | ON f.via_key = v.via_key
8 | WHERE v.br <> 0
9 | GROUP BY v.br
10 | ORDER BY total_acidentes DESC
11 | LIMIT 10;

> See performance \(1\)

```

Table ▾ +

	¹ ₃ br	¹ ₃ total_acidentes
1	101	13014
2	116	11021
3	40	3502
4	381	3496
5	153	2789
6	163	2519
7	364	2264
8	277	2157

Figura 24 – Rodovias federais com maior número de acidentes registrados em 2025.
 Fonte: Elaborado pela autora a partir do Databricks

Resultado: Minas Gerais foi o estado com maior número de acidentes em 2025, com 9.570 ocorrências, seguido por Santa Catarina, com 8.186, e Paraná, com 7.630. Entre as rodovias, a BR-101 apresentou a maior concentração de acidentes, com 13.014 registros, seguida pela BR-116, com 11.021.

4. Quais tipos de acidentes apresentam maior gravidade em relação ao número de vítimas fatais?




Figura 25 – Tipos de acidentes com maior número de vítimas fatais.
Fonte: Elaborado pela autora a partir do Databricks

Resultado: A colisão frontal apresentou o maior número de vítimas fatais, com 1.863 mortes em 4.739 acidentes, seguida pelo atropelamento de pedestre, com 919 mortes em 3.057 ocorrências. Os resultados demonstram que os tipos de acidentes mais frequentes não são necessariamente os que apresentam maior gravidade.

5. Existe relação entre as condições meteorológicas, características da pista e a ocorrência de acidentes?




Figura 26 – Distribuição dos acidentes por condição meteorológica.
Fonte: Elaborado pela autora a partir do Databricks

▶ ✓ Sep 07, 2026 (2s)

```

1 %sql
2 SELECT
3     v.tipo_pista,
4     COUNT(*) AS total_acidentes
5 FROM workspace.gold.fato_acidentes f
6 INNER JOIN workspace.gold.dim_via v
7     ON f.via_key = v.via_key
8 GROUP BY v.tipo_pista
9 ORDER BY total_acidentes DESC;

```

> [See performance \(1\)](#)

Table ▾ +

	^A _C tipo_pista	¹ ₃ total_acidentes
1	Simples	34733
2	Dupla	30782
3	Múltipla	7014

Figura 27 – Distribuição dos acidentes por tipo de pista
 Fonte: Elaborado pela autora a partir do Databricks

Resultado: A maior parte dos acidentes ocorreu em condições de céu claro, com 46.375 registros, e em pistas simples, com 34.733 ocorrências. Os dados permitem identificar uma maior concentração de acidentes nessas condições, porém não são suficientes para estabelecer uma relação causal entre condições meteorológicas, tipo de pista e ocorrência de acidentes.

6. Quais características estão mais presentes nos acidentes com vítimas fatais?

▶

▼

✓

Sep 07, 2026 (2s)

82

```

9 WHERE a.classificacao_acidente = 'Com vítimas fatais'
10 GROUP BY a.tipo_acidente
11 ORDER BY total_acidentes_fatais DESC
12 LIMIT 10;

```

> [See performance \(1\)](#)

Table ▼

+

	A ^B _C tipo_acidente	1 ² ₃ total_acidentes_fatais	1 ² ₃ total_mortos
1	Colisão frontal	1395	1862
2	Atropelamento de Pedestre	902	919
3	Colisão traseira	619	683
4	Saída de leito carroçável	605	700
5	Colisão transversal	427	481
6	Colisão com objeto	297	323
7	Tombamento	268	293
8	Colisão lateral mesmo sentido	212	228
9	Colisão lateral sentido oposto	212	255
10	Queda de ocupante de veícu...	87	89

Figura 28 – Tipos de acidentes mais frequentes entre as ocorrências com vítimas fatais.
Fonte: Elaborado pela autora a partir do Databricks

Resultado: A colisão frontal foi o tipo mais frequente entre os acidentes com vítimas fatais, com 1.395 ocorrências, seguida pelo atropelamento de pedestre, com 902. Esses tipos também apresentaram os maiores números de mortes.

8. CONCLUSÃO

O projeto implementou um pipeline de dados para análise dos acidentes registrados nas rodovias federais brasileiras em 2025.

Os dados foram ingeridos na Camada Bronze, tratados e padronizados na Camada Silver e organizados na Camada Gold por meio de um modelo dimensional. A partir da estrutura criada, foram realizadas consultas para responder às perguntas de negócio definidas no projeto.

A análise permitiu identificar padrões relacionados às causas, períodos, localidades, rodovias, tipos e gravidade dos acidentes, demonstrando a aplicação das etapas de ingestão, transformação, modelagem e análise de dados em um pipeline no Databricks.

9. AUTOAVALIAÇÃO

O desenvolvimento deste MVP foi importante para colocar em prática os conceitos estudados na disciplina de Engenharia de Dados. No início, senti dificuldade para compreender algumas etapas, principalmente o tratamento dos dados e a modelagem dimensional. Porém, conforme o projeto avançou, fui compreendendo melhor o processo e aprimorando a solução.

Ao longo do trabalho, consegui entender de forma mais prática a construção de um pipeline, a arquitetura medalhão com as camadas Bronze, Silver e Gold, a qualidade dos dados e o modelo dimensional em esquema estrela. Apesar das dificuldades iniciais, fiquei satisfeita por conseguir superá-las e concluir o MVP, atendendo aos objetivos e às perguntas de negócio propostas.

Como evolução futura, o pipeline poderá ser automatizado para incorporar novos dados e ampliado com informações de outros anos, permitindo análises históricas e comparações. Também poderão ser incluídas novas fontes de dados e dashboards para complementar as análises.